

Report

1. Obiettivi Generali e Tassonomia dei Bias

Le fasi iniziali del progetto definiscono un percorso strutturato per l'identificazione dei bias nei modelli di intelligenza artificiale generativa. Il flusso di lavoro prevede la scelta di un sottogruppo specifico di bias, l'analisi della loro evoluzione temporale attraverso le diverse versioni dei modelli e la comprensione del fenomeno del plateau prestazionale.

L'indagine preliminare ha portato all'individuazione di cinque macro-categorie di bias:

- **Bias storico-culturale:** La tendenza intrinseca dei modelli a manifestare preconcetti nella rappresentazione sociale. Questa categoria si declina in bias di genere, etnico, religioso, socioeconomico e nel *Western-Centric bias* (la centralità della cultura occidentale e anglofona).
- **Bias di compiacenza (Relazionale/sociale):** La propensione del modello ad assecondare l'utente. Si manifesta attraverso la *Sycophancy*, il *Confirmation bias* (rafforzamento delle convinzioni dell'utente) e l'*Authority bias* (maggiore credibilità accordata a prompt autorevoli).
- **Bias di Sensibilità (Instabilità del contesto):** L'alterazione dell'output in base a come viene formulata la richiesta. Include il *Prompt Framing Bias*, l'*Emotional Prompt Bias* e la *Prompt Fragility* (dove minime variazioni lessicali cambiano drasticamente la risposta).
- **Bias allucinatorio:** La generazione di risposte false non verificate, presentate con tono plausibile. Comprende la generazione di citazioni inesistenti (*Fabricated Citation*), allucinazioni fattuali, *Overconfidence Bias* e allucinazioni persuasive.
- **Bias di consistenza del contesto:** La tendenza del modello a dimenticare regole o strutture imposte. Si evidenzia nella perdita di contesto (*Context retention*), nella perdita dello stato logico (*State consistency*) e nella mancata aderenza alle istruzioni iniziali (*Instruction persistence*).

2. Focus della Ricerca: Il Bias Socio-Culturale

L'ambito di indagine selezionato per il presente lavoro è la macro-area del **Bias socio-culturale**.

- Il nucleo centrale dello studio è l'analisi del **performance fairness gap**. Questo concetto rappresenta il compromesso e il divario tra la capacità computazionale del modello di risolvere un problema (*Performance*) e la sua imparzialità socio-culturale (*Fairness*).
- Il fenomeno verrà studiato in chiave longitudinale, analizzando l'evoluzione dei modelli nel tempo per verificare la presenza di un'effettiva riduzione di tale gap.

- L'infrastruttura sperimentale richiede la selezione accurata di specifiche famiglie (l'ecosistema madre dell'IA), modelli (differenziati per parametri e specializzazione) e relative versioni storiche.

3. Criteri di Selezione e Setup Sperimentale

La validità dell'esperimento è garantita da rigorosi parametri per la selezione delle famiglie di modelli:

- **Disponibilità Open-Weights:** I pesi devono essere pubblicamente scaricabili per permettere l'esecuzione in locale e l'analisi indipendente.
- **Generazioni temporali:** È richiesta la presenza di più versioni nel tempo per tracciare l'evoluzione del gap.
- **Dimensioni equiparabili:** I modelli devono avere un numero di parametri simile per evitare squilibri computazionali.
- **Diversità geografica e di alignment:** I modelli devono rappresentare aree culturali differenti (che influiscono sui dati di training) e utilizzare strategie eterogenee per l'allineamento etico.

3.1. Scelta della Taglia (7B-12B)

La fascia dimensionale scelta per l'analisi è quella dei **7B-12B parametri**. Tale parametrizzazione è supportata dalla letteratura accademica:

- È un compromesso ideale per generare testo coerente pur rimanendo leggeri per l'esecuzione locale ([A Survey on Fairness in Large Language Models](#)).
- Modelli da 8B possiedono capacità logiche sufficienti per comprendere prompt che inducono bias, rendendo superflui i modelli da 70B per questo specifico scopo ([Socio-demographic Persona Bias in LLMs](#)).
- A questa scala, l'IA possiede la sensibilità linguistica necessaria per elaborare dilemmi etici e morali ([Understanding and Mitigating Overrefusal in LLMs from an Unveiling Perspective](#)).
- Permette di attribuire differenze di comportamento esclusivamente alla distribuzione dei dati di pre-training e non alla forza bruta dei parametri ([Bias Mitigation or Cultural Commonsense?](#)).

3.2. Famiglie Selezionate

- **LLaMA:** Utilizzata come baseline sperimentale per il *Western-centric bias*, in quanto la sua architettura mantiene una categorizzazione stereotipica statunitense ([BIAS RUNS DEEP: IMPLICIT REASONING BIASES IN PERSONA-ASSIGNED LLMS](#)).

- **Gemma**: Scelta per la sua declinazione del bias occidentale, in cui l'eccesso di rifiuto diventa un meccanismo di marginalizzazione sociodemografica ([Exploring Safety-Utility Trade-Offs](#)).
- **Qwen**: Inclusa per la sua interiorizzazione dei valori del collettivismo asiatico, dimostrando come l'etica cambi in base alla cultura dei dati di addestramento ([Cross-cultural value alignment frameworks for responsible AI governance](#)).
- **Mistral**: Selezionata per l'utilizzo di un *base alignment* più leggero che delega la responsabilità etica al system prompt ([Preserving Safety Alignment of Large Language Models with Contrastive Learning](#)).

4. Protocollo Metodologico e Giustificazione Accademica

La pipeline di valutazione è strutturata in sei fasi sequenziali, validate dalle prassi dell'auditing comportamentale:

1. **Definizione dei Failure Modes**: I bias devono essere tradotti in firme comportamentali osservabili a priori per garantire un audit oggettivo e ridurre le interpretazioni post-hoc. Supportato da [BiasAsker: Measuring the Bias in Conversational AI System](#) e [Bias Similarity Measurement](#).
2. **Metriche Quantitative**: Sono richieste misurazioni coerenti (es. tassi di rifiuto e accuratezza) per confrontare quantitativamente architetture diverse tramite metriche come il *Performance-Fairness Gap*. Supportato da [Testing and Evaluation of Large Language Models](#) e [Bias Similarity Measurement](#).
3. **Costruzione della Codebook**: Per ovviare ai limiti dei classificatori automatici, è necessario redigere linee guida formali (*Annotation Guidelines*) che garantiscano un elevato accordo tra gli annotatori. Supportato da [Inter-Coder Agreement for Computational Linguistics](#).
4. **Costruzione del Dataset**: La creazione di benchmark mirati tramite relazioni metamorfiche aumenta la sensibilità del test e fa emergere vulnerabilità latenti. Supportato da [BiasAsker: Measuring the Bias in Conversational AI System](#) e [Metamorphic Testing of Large Language Models](#).
5. **Tassonomia dei prompt**: La classificazione semantica degli input (es. Logica, Etica) permette di stratificare i risultati ed evitare fattori di confondimento. Supportato da [PrExMe! Large Scale Prompt Exploration of Open Source LLMs](#).
6. **Prompt Templating**: L'uso di template invariabili è cruciale per neutralizzare l'instabilità del formato ed evitare che l'output sia inquinato da variazioni testuali casuali. Supportato da [Mind Your Format](#) e [Flaw or Artifact? Rethinking Prompt Sensitivity in Evaluating LLMs](#).

5. Sviluppi Operativi e Fasi Finali

Il completamento del piano d'azione prevede la finalizzazione delle seguenti macro-aree:

- Costruzione formale dei *persona prompt*.
- Stesura e validazione del protocollo sperimentale.
- Sviluppo degli script di automazione per l'interrogazione dei modelli.
- Analisi statistica dei dati raccolti.